ChatGPT

SAE–RE 评估流程与运行管线开发文档

执行摘要

本开发/研究说明文档（面向你们项目的 pipeline）定义了一个**可复现、可审计**的评估流程，用于回答如下研究问题：

> 在本地 Llama-3.1-8B（base）上，将预训练 SAE（Llama3_1-8B-Base-L19R-8x）挂接到指定层的 residual stream 后，是否存在**单个或一组 SAE latent**与心理学概念 **RE（Reflective Listening，反射性倾听）**具有“有意义的关系”（统计相关 + 语义可解释 + 具备一定因果影响）？

该 pipeline 的核心思想是：**先确保 SAE 在你的语料域上“重构保真与稀疏性正常”（结构性指标）**，再用你已完成的 **RE vs 非RE 标注**做**概念检测与选择性验证（功能性指标）**，最终通过**干预（ablation/boost）**建立因果证据。SAEBench 明确主张 SAE 不能只用“稀疏–保真 tradeoff”单一指标评估，而应覆盖**重构、概念检测、可解释性、解缠结/干预**等多维能力。[1]

你当前硬约束非常明确：所选 SAE 的 `hyperparams.json` 指定 hook 点为 **`blocks.19.hook_resid_post`**（输入/输出相同），并给出 **d_model=4096、expansion_factor=8、d_sae=32768、JumpReLU** 等关键信息，这些直接决定了管线必须在哪一层、以何种张量形状对齐。[2]

本文件交付三类东西：**明确流程**（含 Mermaid 图）、**明确指标**（定义/公式/输入/解释/可视化）、**明确结论判定规则与最小实验集**（“找到 RE latent(s)” vs “证据不足”）。

系统与资源清单

模型与 SAE 资源（固定）

- Base 模型：本地 `Llama-3.1-8B`（base）。你们在实现时需确保 tokenizer 与模型权重一致（避免 tokenization 差异导致激活分布不可比）。
- SAE：来自你提供的 HuggingFace 路径下的 **Llama3_1-8B-Base-L19R-8x**，其配置声明：
- hook 输入/输出：`blocks.19.hook_resid_post` [3]
- d_model=4096，d_sae=32768（8× overcomplete）[4]
- 激活函数：JumpReLU（带阈值字段）[5]
- 归一化：`norm_activation="dataset-wise"` 且给出 `dataset_average_activation_norm`，意味着推理时最好使用官方/兼容加载器复现同一归一化逻辑，否则 latent 值可比性会下降。[3]
- SAE 物理权重文件：目录下的 `checkpoints/final.safetensors`（用于加载）。[6]

数据资源（你已具备）

- 访谈数据集（两份）：内容为**咨询师 utterance**，你已经完成 **RE vs 非RE** 标注；并且还标有“其它心理学概念”（多标签或多类），这对做对照与区分效度非常关键（见后文）。
- RE 的行为学/心理学定义建议以 MI 编码体系的“反射（Reflection）”为参考：MITI 对反射的编码规则（简单/复杂反射、同一 volley 计数规则等）能帮助你在论文里把 RE 操作化写得更“专业可追溯”，即便你最终不完全采用 MITI 的细分标签。[7]

实现框架建议（非代码、仅依赖策略）

由于 SAE hook 名为 `blocks.19.hook_resid_post`，这与 TransformerLens/SAELens 生态的命名高度一致；SAELens 明确指出其可深度集成 TransformerLens，也可在 HuggingFace Transformers 等任意 PyTorch 模型中用“抽激活 → encode/decode”方式使用。[8]
因此本 pipeline 要求团队在工程上满足的不是“必须用哪个库”，而是“**必须抽取与 SAE 训练时同一语义位置的激活**”。

端到端运行管线

管线总览（Mermaid）

```
flowchart TD
  A[数据集A/B: utterance + label_re + other_labels] --> B[预处理: 清洗/去重/分层抽样/划分train-dev-test]
  B --> C[分词与长度策略: 截断或滑窗; 记录token映射]
  C --> D[前向推理: base Llama3.1-8B]
  D --> E[Hook提取: blocks.19.hook_resid_post 得到 z: T×4096]
  E --> F[SAE编码: h = encode(z) 得到 T×32768 稀疏latent]
  F --> G[SAE重构: z_hat = decode(h)]
  G --> H[结构性评估: MSE/Cos/EV/L2Ratio/LossRecovered/L0/FF等]
  F --> I[RE候选筛选: 单latent统计 + 多重检验 + 排名]
  I --> J[功能性评估: probing/MaxAct/auto-interp/几何/跨数据集一致性]
  J --> K[干预验证: ablation/boost -> 输出变化 -> RE评分]
  K --> L[结论判定与产物: 候选latent清单+证据包+可视化报告]
```

数据预处理与分析单元

分析单元（推荐默认）
- 单元：**咨询师 utterance（你当前标注单位）**。MITI 提醒“解析过细会降低一致性”，这与 RE 作为话语行为的性质一致。[9]

长度策略（必须记录）
因 SAE 在 token 级工作，同一句 utterance 的 token 长度直接影响“max pooling 是否更容易触发”。因此 pipeline 必须在元数据里记录：

- `n_tokens`（分词后长度）
- 是否截断/滑窗
- 截断位置（头/尾）
- 若用滑窗：窗口大小与步长

层与挂接点（必须固定对齐）

该 SAE 的 `hyperparams.json` 明确要求输入输出 hook 点为 **`blocks.19.hook_resid_post`**，并给出 `d_model=4096` 与 `d_sae=32768`。因此管线层选择不是“可选项”，而是**必须**对齐到层 19 的 post-residual 激活。[4]

强制一致性检查（上线前的“冒烟测试”）
在正式跑全量评估前，必须对随机一小批样本做断言检查：

- 张量维度对齐：`z` 最后一维=4096；`h` 最后一维=32768。[3]
- 稀疏性合理：每 token 激活 latent 数（L0）应远小于 32768（见后文 L0 指标解释）。[1]
- Loss recovered 合理：若出现大量负值或接近 0，则优先怀疑 hook 点或归一化未复现（需要回滚检查）。[10]

评估指标说明

本节将指标分成两大类，并给出**定义、公式、所需输入、解释口径、可视化建议**。这跟 SAE 综述和 SAEBench 的“结构性 vs 功能性”划分一致：结构性指标保证 SAE 在该域可用；功能性指标才用于判断“是否与 RE 有意义相关”。[11]

为适配 utterance 标签，你们必须先定义**聚合函数**把 token×latent 的 $h_{i,t,j}$ 变为 utterance×latent 的 $a_{i,j}$，否则任何 RE 指标都不可复现。

统一符号

- i：utterance 样本索引
- t：token 索引
- $z_{i,t} \in \mathbb{R}^{4096}$：hook 点原激活（blocks.19.hook_resid_post）[3]
- $h_{i,t} \in \mathbb{R}^{32768}$：SAE latent 激活[4]
- $\hat{z}_{i,t}$：SAE 重构激活
- $y_i \in \{0,1\}$：RE 标签（1=RE）
- 触发阈值 τ：用于把连续激活定义为“激活/未激活”（建议固定写入配置）

结构性指标（Structural）

这些指标回答：**SAE 在你的 RE 语料域上是否仍然“重构得像、稀疏得合理、替换后不破坏模型行为”。**

MSE（重构误差）
- 公式：$\mathrm{MSE} = \frac{1}{N}\sum_{i,t}\|z_{i,t} - \hat{z}_{i,t}\|_2^2$
- 输入：$z, \hat{z}$
- 解释：越小越好；用于发现“重构崩坏/归一化不一致”。
- 可视化：按数据集 A/B、按 RE/非RE 分组箱线图。

Cosine Similarity（方向保真）
- 公式：$\mathrm{Cos} = \frac{1}{N}\sum_{i,t}\frac{\langle z_{i,t}, \hat{z}_{i,t}\rangle}{\|z_{i,t}\|\|\hat{z}_{i,t}\|+\epsilon}$
- 输入：$z, \hat{z}$
- 解释：越接近 1 越好；可与 MSE 互补（一个看幅值误差，一个看方向偏移）。

Explained Variance（EV）/ FVU（方差未解释比例）
- EV：$\mathrm{EV} = 1 - \frac{\mathrm{Var}(z-\hat{z})}{\mathrm{Var}(z)}$
- FVU：$\mathrm{FVU} = \frac{\sum\|z-\hat{z}\|^2}{\sum\|z-\bar{z}\|^2}$
- 输入：$z, \hat{z}$
- 解释：EV 越大越好；FVU 越小越好。用于跨数据集比较“域外退化”。

L2 Ratio（范数保真）
- 公式：$\mathrm{L2Ratio} = \frac{1}{N}\sum_{i,t}\frac{\|\hat{z}_{i,t}\|_2}{\|z_{i,t}\|_2+\epsilon}$
- 输入：$z, \hat{z}$
- 解释：接近 1 更好；偏离说明系统性缩放，可能影响 logits/困惑度。

Loss Recovered（SAEBench 定义的保真指标，强烈推荐纳入）
SAEBench 明确定义：令
- H_{orig}：原模型 next-token 交叉熵
- H^*：把激活 x 替换为 SAE 重构 $\hat{x}$ 后的交叉熵
- H_0：把激活置零（zero-ablate）后的交叉熵
则

$$\mathrm{LossRecovered} = \frac{H^* - H_0}{H_{orig} - H_0}$$

[1]

- 输入：三次 forward 的交叉熵（orig / recon / zero-ablate）。
- 解释：1=与原模型等价；0=不比置零好；<0=“重构比置零更糟”。
- 可视化：随文本长度、随 batch 的稳定性图；并分 RE/非RE 检查是否存在系统偏置（理想情况下不应相差过大）。

L0 Sparsity（每 token 激活 latent 个数）
- 公式：$\mathrm{L0} = \frac{1}{N}\sum_{i,t}\mathbb{I}(|h_{i,t,j}| > \tau)$ 在 j 上求和
- 输入：h
- 解释：越小越稀疏；但“过稀疏”常导致 LossRecovered 下降。SAEBench 指出需要把稀疏–保真曲线当作必要但不充分指标。[1]

Firing Frequency（latent 触发频率）
- 公式：$\mathrm{FF}_j = \mathbb{P}_{i,t}(|h_{i,t,j}| > \tau)$
- 输入：h
- 解释：用于识别“高频 latent”（常是通用/表面模式）与“死 latent”。高频 latent 往往是 RE 伪相关的高风险来源。

结构性指标最低通过门槛（建议的工程判定口径）
由于不同实现会影响绝对值，本项目不建议硬编码“必须达到某个 MSE 数值”。更稳健的门槛是：

- 在 A/B 两数据集上，LossRecovered 的分布应整体为**正且接近 1 的一侧**，不应大量落在 0 或负值（否则先修复对齐/归一化/替换方式）。[10]
- L0 必须远小于 32768，且 FF 分布应呈长尾（少数频繁，多数稀有），否则说明 SAE 行为异常或阈值设定不合理。[12]

功能性指标（Functional）

功能性指标回答：**哪些 latent 与 RE 相关？它们是否可解释？这种关系在跨数据集上是否一致？是否具备因果影响？**

Token→Utterance 聚合（所有功能指标的公共前置）
你们必须将 $h_{i,t,j}$ 聚合为 utterance 特征 $a_{i,j}$。必须记录使用哪种：

- Max pooling：$a_{i,j}^{max} = \max_t h_{i,t,j}$（推荐默认；更贴近“某一片段触发 concept”）
- Mean pooling：$a_{i,j}^{mean} = \frac{1}{T}\sum_t h_{i,t,j}$
- Top-q Mean：取 top q% token 的均值（折中）

单 latent 的 RE 关联强度（Univariate）
对每个 latent j：

- 均值差：$\Delta\mu_j = \mathbb{E}[a_{i,j}|y=1] - \mathbb{E}[a_{i,j}|y=0]$
- 效应量（Cohen’s d）：$d_j = \frac{\Delta\mu_j}{s_{pooled}}$
- AUC：把 $a_{i,j}$ 当 score 的 ROC-AUC
- 解释口径：
- “统计显著”不等于“有意义”；至少要同时看效应量与 AUC。
- **区分效度**：对同一 latent，比较它对 RE 的效应量 vs 对其它概念标签的效应量（你已具备 other_labels，这是优势）。

Sparse Probing（概念检测；必须带强基线）
SAEBench 的 sparse probing 定义：选择最相关的 k 个 latent，然后在其上训练线性 probe；它强调 k 的选择与“概念是否分布式”相关。 [1]
落地为你们项目的评估项：

- 任务一：RE 二分类（主任务）
- 任务二：RE vs 其它概念（多类/多标签扩展，用于区分效度）
- 指标：ROC-AUC、F1、PR-AUC（若 RE 类不均衡尤需 PR-AUC）
- k 扫描：k∈{1,2,5,20,50}（至少做 1 与 20 两档）
- **基线（强制）**：
- Dense probe baseline：直接用原激活 z（经同样 pooling）训练同类 probe，作为“SAE 是否带来概念提纯”的对照（SAEBench 也使用“LLM baseline probe”做比较）。 [1]
- DiffMean / 简单方法对照：AxBench 显示概念检测上简单差分均值法可能优于 SAE，因此你们必须纳入，避免“看起来很酷但不如简单 baseline”的结论风险。 [13]

MaxAct 人审解释（候选 latent 的语义证据）
对 top-N 候选 RE latent（例如 N=50）输出“latent 卡片”：

- Top 激活 utterance 列表（含是否 RE）
- 触发 token/短 span（token 级定位）
- “RE 命中率”：topK MaxAct 样本中 RE 的比例
- “反例检查”：topK 中非RE 的比例与内容类型（识别伪相关）

MaxAct 类型的解释是 Neuronpedia 等工具链的常见做法。 [14]

自动可解释性评分（Auto-Interp，选做但建议）
SAEBench 给出了“生成解释→基于解释预测哪些样本会激活 latent”的自动可解释性框架。 [15]
你们项目中可将其作为“候选 latent 的附加证据”：

- 仅对候选子集做（例如 top-200），避免成本过高
- 数据敏感则用本地模型做 judge；若允许外部再升级

特征几何（Feature Geometry，冗余/簇）
- 指标：候选 latent 的 decoder 列向量两两余弦相似度矩阵；以及“每个 latent 的最大相似度”（冗余诊断）。SAEBench 也把 maximum cosine similarity 作为 core metrics 的便利输出之一。[16]
- 解释口径：若候选 RE latent 高度成簇，研究叙事应从“单 latent”转为“RE 子空间/latent 组”。

Feature Absorption（吸收现象诊断）
SAEBench 描述了 feature absorption：SAE 可能学出“B except A”这种怪异补集特征，影响可解释性与稳定性。[17]
你们项目建议用已有 other_labels 做更直接的吸收/混淆诊断：

- 若某 latent 对 RE 的效应几乎完全由“某其它概念标签”解释（例如在控制该标签后 RE 效应消失），则将其降级为“混淆 latent”，不作为 RE 证据核心。

跨数据集一致性（Cross-dataset consistency，强烈推荐）
你有两个数据集，这是非常关键的可信度来源。推荐至少报告：

- Top-K latent 集合重叠率：Jaccard(C_A, C_B)
- 排名相关：Spearman(效应量排名 A vs B)
- 交叉训练测试：用数据集 A 选 latent/训练 probe，在 B 上测试（反之亦然）

一致性成立时，才能说“latent 与 RE 的关系不是数据集特定伪相关”。

干预效应量（Intervention Outcome Effect Size）
最终“有意义相关”建议必须包含至少一种干预证据（见下一节），并用效应量量化：例如 ΔRE-score、Δlogit、Δprobe-acc 等。SAEBench 中多处指标（如 RAVEL/TPP/SCR）本质都是通过 ablation/替换来衡量“选择性影响”。[18]

候选 latent 筛选与统计检验规范

目标：从 32768 个 latent 中选出小集合，控制假阳性，并支持“跨数据集复现”。

单 latent 统计检验（最小集合）

对每个 latent j（在 utterance 聚合后）至少计算：

- 效应量：Cohen’s d（或 Cliff’s delta，适合非正态）
- AUC（分类可分性）
- 显著性：建议用**置换检验（permutation test）**或 Mann–Whitney U（更稳健）而不是只用 t-test（因为稀疏激活分布往往重尾/零膨胀）

多重假设校正（强制要求）

32768 次假设检验必须做 FDR 控制：

- 推荐：Benjamini–Hochberg（BH-FDR）
- 报告：q-value，并明确你们选择候选 latent 的 q 阈值（例如 q<0.05）

排名与候选集合定义（建议标准化）

建议定义一个统一的候选打分函数，结合“效应 + 可分性 + 稳健性”：

$$Score_j = w_1 \cdot \mathrm{rank}(d_j) + w_2 \cdot \mathrm{rank}(\mathrm{AUC}_j) + w_3 \cdot \mathbb{I}(q_j < q_0)$$

并把 w_1, w_2, w_3, q_0 固化到配置中，保证可复现。

混淆控制与区分效度（利用你的 other_labels）

你有额外心理学概念标签，这是“把 RE latent 说清楚”的关键。建议加入两类分析：

- **多变量回归**：以 RE 为因变量，以候选 latent + 其它概念标签为自变量，观察 latent 在控制其它标签后是否仍显著。
- **负对照概念**：在同一 pipeline 下，检验候选 RE latent 对“某个无关概念”的效应应显著更弱，否则可能只是“通用咨询语气/礼貌句式”特征。

输出要求：在报告中明确区分
- “RE 特异性 latent”
- “通用咨询风格 latent”
- “与其它概念混淆/吸收 latent” [17]

干预实验设计与验证协议

仅相关不足以支撑“meaningfully related”。本节定义你们项目用于建立因果证据的最小干预集合，并给出测量协议。

干预类型（至少选一种，推荐两种都做）

Latent ablation（置零/压制）
- 操作：对候选 latent 集合 S 将 $h_{i,t,j}$ 置零（或夹到极小值）。
- 目的：若 RE 行为依赖这些 latent，则置零应降低 RE 相关输出或降低 RE probe 得分。

Latent boosting（增强/注入）
- 操作：对 $h_{i,t,j}$ 加上固定偏置或放大（注意不要破坏整体激活分布；可用分位数策略）。
- 目的：增强应提高 RE 风格输出，或提高 RE probe 得分。

SAEBench 提醒：在某些评估中，会把“原始重构误差项”加回去，以避免未建模误差导致的广泛副作用干扰；你们在做激活替换/干预时也应记录是否采用类似策略，并做敏感性分析。 [19]

干预测量目标（你们项目的“RE 行为评分”）

你们已有 RE 标签数据，因此推荐两条互补测量路径：

- **判别式测量（classification-based）**
- 用 RE probe（在 held-out 上验证过）对模型输出进行评分：比较干预前后 RE 概率/得分变化（Δprob、Δlogit）。
- **生成式测量（generation-based）**
- 固定一组“来访者输入”（可从你们数据里抽取，或构造标准化提示），让模型生成咨询师回应；用同一个 RE 判别器或人工准则统计“反射句比例、复述结构出现率”等。
- 可参考 MI 体系中对反射行为的例子与判别规则来构造人工核查 checklist（例如是否复述内容/情绪、是否添加意义等）。 [7]

干预效应量与判定口径（必须量化）

对每个候选集合 S 报告至少：

- $\Delta\text{RE-score} = \mathbb{E}[\text{score}_{after}] - \mathbb{E}[\text{score}_{before}]$
- 置信区间：bootstrap 95% CI 或置换检验 p-value
- 副作用指标：LossRecovered 变化或输出困惑度变化（防止“靠破坏语言质量换取 RE 得分变化”）

如果 boosting 能提高 RE 分数，但同时 LossRecovered/生成质量显著下降，则这属于“不可用的因果操控”，应在结论中降级处理。[10]

基线、控制组、结论判定与交付物

必须基线与控制（不做则结论风险极高）

Dense probe baseline（强制）
用原始激活 z（相同 pooling）做同样 RE probe，作为“SAE 是否真的提纯概念”的对照。SAEBench 的 sparse probing 也强调需与非 SAE 表征对比。[1]

DiffMean/简单方法 baseline（强制）
AxBench 显示在概念检测上差分均值等简单方法可能优于 SAE，必须纳入以避免“SAE 并无优势但误判成功”。[13]

随机 latent 控制（强制）
从 32768 个 latent 中采样随机集合 S_{rand}（与候选集合大小相同），重复干预与评估，确保效果不是“随便改几个 latent 都会变”。

层位对照（强烈建议）
如果你们未来会扩展到其它层（同 repo 下其它 LxR-8x），建议至少做一个不同层的 SAE 作为对照；Llama-Scope 命名约定清晰（L[Layer][Position]-[Expansion]x），可帮助扩展。[20]

最小实验集（MVP 交付要求）

在不追求任何“现成代码”的前提下，你们项目应至少跑完并产出：

- **结构性指标报告**：MSE、Cos、EV/FVU、L2Ratio、LossRecovered、L0、FF（按 A/B、RE/非RE 分组）[1]
- **候选 latent 清单**：Top-200（含效应量、AUC、q-value、FF、跨数据集一致性指标）
- **Sparse probing 报告**：k={1,20}，并与 dense baseline、DiffMean baseline 对照[21]
- **MaxAct 人审卡片**：Top-50 候选 latent 的例句与触发 token 证据[14]

“找到 RE latent(s)”的判定规则（建议写进你们项目 README）

建议把“找到”定义为“证据组合成立”，而不是某一个分数高：

判定为“找到 RE 相关 latent(s)”需要同时满足：

- **可用性门槛**：结构性指标通过（尤其 LossRecovered 不应接近 0 或大量为负）。[10]
- **统计证据**：候选 latent 在 A/B 两数据集上对 RE 的效应一致（至少 top-K 有显著重叠或排名相关显著），且 BH-FDR 后仍显著。

- **区分效度**：在控制 other_labels 后仍保留 RE 特异性（不被其它概念解释掉）。 [22]
- **因果证据（至少一种）**：对候选集合做 ablation/boost 后，RE-score 变化显著且优于随机 latent 控制，并且副作用（语言质量/保真度）可接受。 [19]

判定为“证据不足”的常见情况（也要写清楚）

- SAE 在你的语料域 LossRecovered 很差（先修复 hook 对齐/归一化/替换策略）。 [23]
- 只有单数据集有效，跨数据集不复现（更像数据集伪相关）。
- 干预能改变 RE-score，但随机 latent 也能改变（非特异性）。
- 候选 latent 高度高频、明显捕捉表面词形（例如固定短语），MaxAct 证据不支持“反射性倾听”的话语行为解释。

交付物清单（你们项目应落盘的 artifacts）

- `metrics_structural.json`：结构性指标（分组统计 + 分布摘要）
- `metrics_functional.json`：功能性指标（probe、MaxAct、几何、跨域一致性）
- `candidate_latents.csv`：候选 latent 排名表（含所有字段）
- `latent_cards/`：Top-50 latent 人审卡片（HTML/Markdown）
- `intervention_report.md`：干预设置、效应量、随机对照结果、可视化
- `decision.md`：按上面的判定规则给出最终结论与理由（可审计）

可复现性、风险与常见坑

对齐风险（最高频故障源）
- SAE 规定 hook 点是 `blocks.19.hook_resid_post`；若你们在 HF Transformers 中抓的是“layer output”但位置不一致，会导致 latent 行为完全不可信。务必以“张量语义位置一致”作为要求，而不是层号一致。 [24]

归一化风险（隐蔽但致命）
- SAE 声明 `norm_activation="dataset-wise"` 并给出训练集平均范数；若推理未复现，latent 激活分布会漂移，从而影响阈值 τ、L0、FF、以及所有 RE 统计。 [3]

只看稀疏–保真 tradeoff 的风险
- SAEBench 明确指出稀疏–保真曲线必要但不充分，且不同指标可能给出相互矛盾的排序，因此必须做多指标评估。 [1]

缺少强基线的风险
- AxBench 与“Are SAEs Useful”这类工作都强调：SAE 不一定优于简单基线，必须纳入 DiffMean、dense probe 等对照，否则研究结论说服力不足。 [25]

统计陷阱
- 32768 次检验不做 FDR 控制必然假阳性泛滥。
- 稀疏激活分布强非正态，优先置换检验/秩检验，并报告效应量而不仅 p-value。

伦理与数据安全
- 若访谈数据敏感，自动可解释性（LLM judge）应优先本地化；若必须外发，需脱敏与合规流程。SAEBench 的 auto-interp 是 LLM-as-judge 框架，可被本地模型替代，但需在文档中注明局限。 [15]

---

[1] [10] [16] [18] [21] https://arxiv.org/pdf/2503.09532v3
https://arxiv.org/pdf/2503.09532v3

[2] [3] [4] [5] [12] [23] [24] https://huggingface.co/OpenMOSS-Team/Llama3_1-8B-Base-LXR-8x/blob/main/Llama3_1-8B-Base-L19R-8x/hyperparams.json
https://huggingface.co/OpenMOSS-Team/Llama3_1-8B-Base-LXR-8x/blob/main/Llama3_1-8B-Base-L19R-8x/hyperparams.json

[6] https://huggingface.co/OpenMOSS-Team/Llama3_1-8B-Base-LXR-8x/tree/main/Llama3_1-8B-Base-L19R-8x/checkpoints
https://huggingface.co/OpenMOSS-Team/Llama3_1-8B-Base-LXR-8x/tree/main/Llama3_1-8B-Base-L19R-8x/checkpoints

[7] [9] https://motivationalinterviewing.org/sites/default/files/miti4_2.pdf
https://motivationalinterviewing.org/sites/default/files/miti4_2.pdf

[8] https://github.com/decoderesearch/SAELens
https://github.com/decoderesearch/SAELens

[11] https://arxiv.org/abs/2503.05613
https://arxiv.org/abs/2503.05613

[13] [25] https://arxiv.org/abs/2501.17148
https://arxiv.org/abs/2501.17148

[14] https://www.neuronpedia.org/explanation-type/np_max-act
https://www.neuronpedia.org/explanation-type/np_max-act

[15] [17] [19] [22] https://arxiv.org/html/2503.09532v3
https://arxiv.org/html/2503.09532v3

[20] https://huggingface.co/OpenMOSS-Team/Llama-Scope
https://huggingface.co/OpenMOSS-Team/Llama-Scope